

Classificazione Fine-Grained SU CUB-200-2011

Emma Villa - 885906
Nicolò Molteni - 933190



Indice

01

dataset

introduzione al dataset e
pipeline di augmentation

02

modelli

spiegazione dei modelli
impiegati per classificare

03

valutazione

introduzione alle metriche
e valutazione

04

sviluppi futuri

possibili improvement
della pipeline

05

conclusioni



01

II dataset



CUB-200-2011

Caltech-UCSD Birds-200-2011 riconosciuto come benchmark di riferimento per task di classificazione fine-grained.

- 11.788 immagini classificate in 200 classi.
- Flickr + Amazon Mechanical Turk.



Le varianze

Gli uccelli all'interno del dataset presentano una varianza di due tipologie:

- **inter-classe**, esistono alcune specie di uccelli che si differenziano per sottili caratteristiche morfologiche.

baird sparrow



vesper sparrow



- **intra-classe**, gli uccelli della stessa specie si possono trovare in pose differenti rendendo complicata la classificazione.

canada warbler




canada warbler



Problemi del dataset

Sbilanciamento, non tutte le classi sono rappresentate allo stesso modo. Il numero massimo di istanze per classe è pari a 60 mentre il numero minimo è 41.




Problemi del dataset

Dimensioni non omogenee delle figure. Le immagini hanno dimensioni molto differenti, di conseguenza la strategia di resize applicata successivamente potrebbe non essere ottimale.

La pipeline di resizing applicata per sistemare questo problema è la seguente:

- **Resize**
- **Center Crop**



Suddivisione del dataset

La suddivisione del dataset fornita è la seguente:

- Train-set 5.094 immagini
- Test-set 5.794 immagini
- Validation-set 900 immagini

È stata presa la decisione di non ri-eseguire lo split generando un canonico 80-20 ma piuttosto di sfruttare una buona pipeline di **data augmentation** per incrementare la quantità e la variabilità dei dati. Questo processo è utile anche alla diminuzione dell'overfitting.


Data augmentation

A ciascuna immagine viene applicato un random flip, le trasformazioni più forti ("strong") sono applicate sfruttando una pipeline **probabilistica** ($p = 70\%$). Questo processo è utile per mantenere i dettagli più fini necessari a riconoscere alcuni uccelli.

Le trasformazioni strong sono:

- rotazione
- random zoom
- shear
- traslazione
- random contrast
- random brightness

Augmented 1



Augmented 2



Augmented 3



Augmented 4




Augmented 5



Augmented 6




Augmented 7



Augmented 8



Augmented 9



Preprocessing finale

Prima di eseguire il fitting è stato necessario eseguire altre due trasformazioni:

- **normalizzazione**, i valori dei pixel sono stati normalizzati dall'intervallo [0, 255] all'intervallo [-1, 1] per essere compatibili con i modelli impiegati.

$$x_{norm} = \frac{x}{127.5} - 1$$

dove x è il valore del singolo pixel dell'immagine.

- **one-hot encoding**, tutte le label del dataset sono state rappresentate in one-hot encoding per renderle compatibili con l'approccio neurale.



02

I modelli



I modelli selezionati


I modelli selezionati sono i seguenti:

- **MobileNetV2** (3.5M), un modello leggero con pochi parametri, è stato scelto per vedere se con poche immagini di training a disposizione potesse estrarre buone features.
- **ResNet50V2** (25.2M), **InceptionV3** (23.9M), due modelli circa 7 volte più grandi di MobileNetV2, sono stati scelti per capire se un'architettura più grande potesse estrarre feature migliore ed essere più utile in un task di tipo fine-grained.

MobileNetV2

Evoluzione di MobileNet, utilizza i blocchi **inverted residuals with linear bottleneck**.

In questi blocchi l'informazione fluisce espandendo un input a bassa dimensionalità verso l'alta dimensionalità. Filtrando i dati tramite una convoluzione depthwise e ri-proiettando le feature a bassa dimensionalità.



ResNet50V2

Rete residuale profonda, trasforma le funzioni del blocco residuale in pure addizioni. Questo design agevola l'addestramento, perchè la rete deve solo approssimare la funzione residuale allo zero invece di imparare la funzione identità da zero.


$$\begin{aligned} \mathbf{y}_l &= h(\mathbf{x}_l) + \mathcal{F}(\mathbf{x}_l, \mathcal{W}_l) \\ \mathbf{x}_{l+1} &= f(\mathbf{y}_l) \end{aligned}$$

Dove:

- $\mathbf{x}_l$ e $\mathbf{x}_{l+1}$ sono rispettivamente l'input e l'output del blocco residuo corrente;
- $\mathbf{y}_l$, output del blocco residuo;
- $\mathcal{W}$, parametri del modello
- h, f , funzioni identità
- $\mathcal{F}$, funzione residuale, al suo interno contiene BatchNormalization e funzione di attivazione.

ResNet50V2


Resnet50V2 adotta un design a bottleneck (1×1 , 3×3 , 1×1), per prevenire il problema del vanishing gradient.



InceptionV3

InceptionV3 ha l'obiettivo di massimizzare la profondità e l'ampiezza minimizzando allo stesso tempo il numero di parametri.

- Scompone operazioni spaziali complesse in sequenze più piccole
- Sostituisce convoluzioni quadrate con sequenze asimmetriche (es: $1 \times n$ seguita da $n \times 1$) per mantenere alta capacità espressiva
- Applica filtri convoluzionali di diverse dimensioni in parallelo per catturare sia dettagli fini che forme globali
- Mitiga il vanish gradient tramite classificatori ausiliari





03

La valutazione e



Le metriche

I modelli sono stati valutati sfruttando due tipologie di metriche:

- **puntuali:** sono state calcolate le metriche pesate per ovviare al problema del dataset sbilanciato.
 - weighted accuracy (top-1 e top-5)
 - weighted recall
 - weighted F1-score
- **grafiche:**
 - ROC curve
 - PR curve

La strategia di calcolo applicata è la **macro-average** in modo tale da considerare lo sbilanciamento del dataset.

Accuracy

Misura la percentuale di campioni per i quali la classe predetta con la probabilità più alta coincide esattamente con l'etichetta reale

$$\text{Top-1 Accuracy} = \left(\frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i) \right) \cdot 100$$

Dove:

- N , il numero delle classi;
- y_i , la classe predetta;
- $\hat{y}_i$, la ground truth;
- $\mathbb{I}$, funzione di verità.

Recall

misura la capacità del classificatore di individuare correttamente tutti i campioni appartenenti a una specifica classe. È importante per valutare la capacità del modello nell'identificare differenze intra-classe.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Dove:

- TP, true positive,
- FN, false negative.

Precision

offre una valutazione della capacità del modello nell'identificazione corretta della classe target all'interno di un ampio insieme di categorie simili. È utile per la differenza inter-classe.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Dove:

- TP, true positive;
- FP, false positive.

F1 score

valuta le capacità del modello nel mantenere un equilibrio ottimale nel distinguere i dettagli fini senza perdere capacità di generalizzazione. È la media armonica tra Precision e Recall.

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$$

ROC curve e PR curve

La **curva ROC** mostra la capacità del classificatore nel discriminare le classi al variare della soglia di decisione.

Dove:

- FP, false positive;
- TN, true negative.

$$FPR = \frac{FP}{FP + TN}$$

La **curva PR** rappresenta l'andamento della Precision rispetto alla Recall. In una valutazione One-vs-Rest, dove i campioni negativi superano di gran lunga quelli positivi, questa metrica evita che le prestazioni vengano sovrastimate.

Valutazione

La tabella seguente mira a confrontare le architetture in termini di accuratezza, tempi di addestramento e funzione di costo (se disponibile).

- **MobileNetV2 e ResNet50V2** hanno raggiunto livelli di accuratezza e tempi comparabili.
- **InceptionV3 e Feature extraction fine-tuned** si mostrano superiori a tutti gli altri modelli testati.
- **Custom CNN** presenta dei limiti dovuti all'addestramento da zero su un dataset piccolo.

Modello	Accuracy		Loss		Tempo
	Training	Test	Training	Test	
MobileNetV2	0.659	0.693	1.249	1.122	14.65 min
ResNet50V2	0.757	0.694	0.987	1.132	23.08 min
InceptionV3	0.811	0.758	0.817	0.877	16.60 min
Feature extraction	-	0.662	-	-	8.47 min
Feature extraction fine-tuned	-	0.766	-	-	* 4.77 min
Custom CNN	0.303	0.312	3.588	3.632	42.62 min


* relativo solo alla fase di estrazione delle feature

Valutazione

Il grafico mostra una comparazione tra le metriche puntuali.

InceptionV3: il poligono più ampio conferma la superiorità del modello e della sua versione Feature Extraction fine-tuned

I poligoni risultano regolari su tutti i modelli, mostrando un buon equilibrio tra Precision e Recall.




Valutazione

La curva ROC mostra che i modelli di Transfer Learning si avvicinano all'angolo superiore sinistro, massimizzando l'area sottesa dalla curva (AUC)

- I modelli assegnano quasi sempre il punteggio di confidenza più alto alla classe corretta.

La curva PR mostra che InceptionV3 mantiene una curva alta, quindi genera pochi falsi positivi. Mentre MobileNetV2 e ResNetV2 mostrano un decadimento più veloce, all'aumentare della Recall.





04

Sviluppi Futuri



Sviluppi futuri

possibili miglioramenti introducibili in:

- **fitting dei modelli:**
 - introdurre dei pesi da assegnare alle classi per risolvere il problema di sbilanciamento del dataset.
- **pipeline di resize:**
 - crop delle immagini eseguito sul soggetto sfruttando le bounding box fornite;
 - implementazione di una nuova pipeline di augmentation che permetta una migliore generalizzazione.



05

Conclusion

i



Conclusioni

- **Superiorità del Transfer Learning:** L'addestramento da zero ha evidenziato chiaramente i limiti dell'apprendimento senza una conoscenza pregressa.
- **Fine Tuning vs Feature Extractor:** la feature extraction semplice si è mostrata una buona base, ma si è rivelata inferiore al Fine-Tuning completo.
- **Modelli ottimali:** InceptionV3 si è confermata la soluzione migliore, anche nella versione Feature-Extractor fine-tuned.
- **Alternativa efficiente:** MobileNetV2 ha raggiunto prestazioni competitive mantenendo un costo computazionale inferiore.

Reference

- [1] WAH, C., Branson, S., Welinder, P., Perona, P., & Belongie, S. (2011). The Caltech-UCSD Birds-200-2011 Dataset (Published). California Institute of Technology.
<https://authors.library.caltech.edu/records/cvm3y-5hh21>
- [2] SANDLER, Mark, et al. Mobilenetv2: Inverted residuals and linear bottlenecks. In: Proceedings of the IEEE conference on computer vision and pattern recognition. 2018. p. 4510-4520. <https://doi.org/10.48550/arXiv.1801.04381>
- [3] HE, Kaiming, et al. Identity mappings in deep residual networks. In: European conference on computer vision. Cham: Springer International Publishing, 2016. p. 630-645.
<https://doi.org/10.48550/arXiv.1603.05027>
- [4] SZEGEDY, Christian, et al. Rethinking the inception architecture for computer vision. In: Proceedings of the IEEE conference on computer vision and pattern recognition. 2016. p. 2818-2826. <https://doi.org/10.48550/arXiv.1512.00567>